Çalışma

Bu çalışma, 2025-2030 yılları arasında Türkiye'nin elde edeceği sağlık bütçesini hangi şehirlere ne oranda vermesi gerektiğini makine öğrenmesi modelleri kullanarak hesaplamaktadır.

Çalışma Amacı

- Çalışmanın birinci kısmında, şehir bazlı 2002-2024 yılları arasındaki hastane, yatak, hastane personeli ve nüfus verileri alınmıştır. Bu veriler makine öğrenmesi modellerine sokularak il bazlı olarak hastane, yatak ve hastane personel sayısı modellemeleri kurulmuştur. En yüksek tahmin oranına sahip modeller ile 2025-2030 yılları için hastane, yatak ve hastane personeli tahmini yapılmıştır.
- Çalışmanın ikinci kısmında TOPSIS adı verilen parametreler ayarlanmıştır. TOPSIS, en iyi ideal çözümü bulmak için yapılan sıralamadır. Bu kapsamda, hastane personel oranları sadece nüfus kullanılarak yapılamaz. Hastaların yaşı, doktor ve yatak eksikliği gibi verilere bakılmalıdır. Bu kapsamda, şehir bazlı 2007-2025 arasındaki 0-14 ve 65+ yaş miktarları ve şehir bazlı 2002-2024 arasındaki bin kişi başına doktor ile yüz bin kişi başına yatak sayıları alınmıştır. Alınan verilerle makine öğrenmesi modeli kurulmuş ve en iyi sonucu veren makine öğrenmesi modelleriyle 2025-2030 yılları arasındaki tahminler yapılmıştır.
- Çalışmanın üçüncü kısmında, 1999-2024 arasındaki Türkiye Sağlık Harcama Listesi tablosu ve 1999-2024 dolar kuru alınmıştır. Alınan veriler ile en iyi tahmini yapan makine öğrenmesi modeli kurulmuş, kurulan model ile Türkiye'nin dolar bazında 2025-2030 yılları arasındaki sağlık bütçesi hesaplanmıştır.
- Çalışmanın son kısmında, daha önceden hesaplanan 2025-2030 TOPSIS verileri ile bir önem sırası yapılmıştır. Sağlık konusunda en çok yardıma ihtiyaç duyan şehir 1. sırada olacak şekilde sıralanmıştır. Devamında, 2025-2030 yılları arasındaki sağlık bütçesi, yardıma ihtiyaç duyan şehirlere ihtiyaç miktarı kadar dağıtılmıştır. Her dağıtım sonrası, ihtiyaç duyan şehirler listesi tekrar güncellenmiştir.

Nufüs Bazlı Gelecek Modellemesi

Veri Seti

- 2002-2024 yıllar arasında şehir bazlı olarak hastane, hastane yatak ve sağlık personeli (asistan, pratisyen, uzman, ebe, hemşire, diğer) verileri toplandı.
- 2002-2025 ve 2030 yıllarında şehir bazlı olarak nufüs sayıları alındı.
- Gelecek tahmini için Şehir bazında nüfus sayısı için TÜİK'ten 2023-2030 nüfus tahmin projeksiyonu alındı.

Veri Ön İşleme

- 2024, 2025 ve 2030 yıllarındaki şehir bazlı nufüs verileri kullanılarak TÜİK'in 2023-2030 nufüs projeksiyonu veri seti tekrar hesaplandı.
- Oluşan yeni hesap ile 2025-2030 veri seti oluşturuldu. Bu veri seti içerisindeki 2025 ve 2030 yılları gerçek verileri oluşturmakta, 2026, 2027, 2028 ve 2029 ise tahmini verileri oluşturmaktadır.

2002-2024 Tekli Modelleme

- Tahmin öncesinde her bir veri için öznitelikler girildi.

```
feature_map = {
    "doktor":  ["yıl", "nufus", "hastane", "yatak", "hemsire", "ebe", "diger"],
    "ebe":     ["yıl", "nufus", "hastane", "yatak", "doktor", "hemsire", "diger"],
    "diger":   ["yıl", "nufus", "hastane", "yatak", "doktor", "hemsire", "ebe"],
    "hemsire": ["yıl", "nufus", "hastane", "yatak", "doktor", "ebe", "diger"],
    "yatak":   ["yıl", "nufus", "hastane", "doktor", "hemsire", "ebe", "diger"],
    "hastane": ["yıl", "nufus", "yatak", "doktor", "hemsire", "ebe", "diger"],
}
```

- Asistan sayısı bazı illerde sıfır olduğu için ve çok düşük verdiği için asistan, pratisyen ve uzman sayısı birleştirildi.
- Tahminlemenin daha iyi olmasını sağlamak için k-fold yaklaşımı kullanıldı ve toplam 5 fold'a ayrıldı.
- Tahmin için 17 farklı model denendi. Deneme sonuçlarında elde edilen başarı sonuçları aşağıdaki gibi verilmiştir.

```
========== GENEL MODEL KARŞILAŞTIRMASI ==========
                Model  Accuracy     MAE     RMSE    R2  ErrorRate  Precision  Recall    F1
          HoltWinters    91.594 176.692  573.802 0.972      8.406      0.983   0.956 0.969
                ARIMA    90.886 221.379  768.090 0.947      9.114      0.990   0.930 0.959
              Prophet    90.527 202.769  684.702 0.963      9.473      0.985   0.943 0.963
               Voting    86.059 247.361  820.054 0.941     13.941      0.951   0.961 0.955
           ExtraTrees    85.708 240.752  759.110 0.951     14.292      0.952   0.957 0.953
             CatBoost    85.553 247.939  823.359 0.935     14.447      0.955   0.954 0.953
              XGBoost    85.447 264.961  895.543 0.922     14.553      0.951   0.959 0.954
HistGradientBoosting    85.269 335.039 1426.567 0.829     14.731      0.952   0.962 0.955
        RandomForest    85.185 263.475  847.860 0.938     14.815      0.952   0.961 0.955
             Bagging    85.138 265.499  870.723 0.937     14.862      0.951   0.961 0.954
    GradientBoosting    85.073 250.023  757.372 0.948     14.927      0.947   0.962 0.953
                 KNN    84.322 315.746 1095.361 0.914     15.678      0.955   0.936 0.943
    LinearRegression    77.584 254.076  526.481 0.940     22.416      0.951   0.951 0.950
               Ridge    76.197 256.111  526.497 0.940     23.803      0.957   0.947 0.952
            Stacking    76.139 352.220  868.405 0.892     23.861      0.946   0.967 0.955
          ElasticNet    75.101 277.180  601.941 0.937     24.899      0.950   0.964 0.957
                 SVR    60.046 829.923 3287.621 0.244     39.954      0.900   0.964 0.926

========== HER HEDEF İÇİN EN İYİ MODEL (Fold 5) ==========
  Hedef       Model  Accuracy        MAE         RMSE       R2
hastane       ARIMA 95.956145   0.654135    1.411002 0.997327
    ebe     Prophet 94.087330  39.546462   76.632831 0.992825
hemsire  ExtraTrees 93.937346 166.520514  421.617079 0.994119
  yatak       ARIMA 92.710238 264.545726  837.159518 0.980082
 doktor HoltWinters 91.975715 231.135847  685.106223 0.986075
  diger       ARIMA 90.598394 375.372619 1146.702571 0.956053
```

- HoltWinters, ARIMA ve Prophet modelleri en iyi sonuçları verdi. Bunun yanında her hedef için hangi modellemenin daha iyi sonuçlar verdiği de listelendi.
- ARIMA modeli, sabit trendlerde artış veya azalış göstermediği için hastane sayısı gibi sürekli değişmeyen tahminlerde çok iyi sonuç verdi.

- HoltWinters ise kısa zamanlı değişen trendleri fark ederek genel oranda en iyi sonucu verdi.
- LSTM ve GRU modelleri denenmedi. Bunun sebebi, literatür araştırıldığında LSTM ve GRU modellerinin 2002-2024 yıllarındaki toplam 22'lik veri setini çok yetersiz görmesidir. Bu modeller daha yüksek sayıda veride iyi sonuç vermektedirler.

2002-2024 Ensemble Modelleme

- Farklı tahminler için farklı modeller en iyi sonucu verdiği için ensemble model kurulmasına karar verildi.
- Bu bağlamda, her tahmin için en iyi 3 sonucu veren model, performans katsayılarına göre birleştirildi.

```
========== HER HEDEF İÇİN TOP-K MODEL VE AĞIRLIKLAR ==========
  Hedef                Model  Accuracy        MAE        RMSE  Agirlik
  diger                ARIMA 90.598394 375.372619 1146.702571 0.336859
  diger          HoltWinters 90.478957 379.220052 1206.847747 0.336415
  diger HistGradientBoosting 87.873100 607.133129 2742.472716 0.326726
 doktor          HoltWinters 91.975715 231.135847  685.106223 0.337337
 doktor                ARIMA 90.619329 300.440868  947.615696 0.332362
 doktor             CatBoost 90.057644 283.047003 1082.125630 0.330302
    ebe                ARIMA 93.776671  34.045168   68.273248 0.345603
    ebe          HoltWinters 92.300293  39.515053   64.821849 0.340162
    ebe         RandomForest 85.264967  82.050586  127.816354 0.314234
hastane                ARIMA 95.956145   0.654135    1.411002 0.356412
hastane          HoltWinters 93.197268   0.974772    1.572279 0.346165
hastane               Voting 80.074442   2.558210    5.837821 0.297423
hemsire           ExtraTrees 93.937346 166.520514  421.617079 0.334710
hemsire               Voting 93.531235 198.314161  551.330462 0.333263
hemsire              XGBoost 93.184293 219.762991  624.091181 0.332027
  yatak                ARIMA 92.710238 264.545726  837.159518 0.341418
  yatak          HoltWinters 92.032737 263.946537  882.777760 0.338923
  yatak             CatBoost 86.801386 273.434879  530.160839 0.319658
```

- Devamında ensemble model birleştirilmesi gerçekleştirildi.

```
========== ENSEMBLE METRİKLERİ (HEDEF BAZINDA) ==========
  Hedef  Accuracy        MAE        RMSE       R2  Precision   Recall       F1
  diger 90.814292 354.194404 1003.491791 0.966345   0.993333 0.919753 0.955128
 doktor 92.498763 258.360833  875.994045 0.977234   0.993671 0.969136 0.981250
    ebe 91.850627  42.385994   66.102373 0.994662   0.963636 0.981481 0.972477
hastane 92.527137   0.949115    1.579661 0.996650   0.994318 0.988701 0.991501
hemsire 93.909991 183.656040  512.584522 0.991307   0.987500 0.975309 0.981366
  yatak 92.721836 207.703415  531.968854 0.991957   0.958084 0.987654 0.972644
```

- Ensemble modelleme, bazı tahminler için tekil modellerden daha düşük sonuçlar verdiği görüldü. Ancak burada ARIMA tuzağına girilmiş olundu. ARIMA tuzağı, hastane gibi sürekli değişmeyen ve bazı yıllar hiç artış göstermeyen şehirlerde 4 yıllık periyot için tamamen sabit değer vermesi, bu sebeple doğruluk oranının %100 çıkmasıdır. Örnek olarak Bayburt şehrinde 2021-2024 yılları arasında yeni hastane yapılmadıysa ve ARIMA 2021'deki sayıyı doğru bildiyse, o da 2024'e kadar hiçbir değişiklik yapmadan

veriyi %100 bilebilmektedir. Ancak 2025-2030 gelecek tahminleri yapıldığında ARIMA hala sabit sonuç vereceği için gelecek tahmini yanlış olacaktır. Bu sebeple, ensemble modelleme kuruldu ve değişken şekilde tahmin oluşturuldu.

2025-2030 Tahminleri

- Tekil modellerdeki ağırlık oranları ensemble modeldeki gibi birleştirildi ve yeni ensemble model ile 2025-2030 yılları aralığındaki veriler tahmin edildi.

Topsis Bazlı Modelleme & Birleşim

Veri Seti

- TÜİK'ten 2007-2025 aralığındaki 0-14 yaş ve 65+ yaş verileri alınmıştır.
- TÜİK'ten 2002-2024 aralığındaki bin kişi başına doktor oranı ve yüz bin kişi başına yatak sayısı veri setleri alındı.

Tekli Modelleme

- İlk olarak amacımız, elimizdeki verilerle hangi modelin en iyi tahmini yaptığını bulmak, sonra da 2030 yılına kadar tahmin verileri oluşturmaktır. Bu sayede topsis verilerini nüfus verileri ile önem durumuna göre çarpacağız.
- Nüfus bazlı gelecek modellemesinde kullanılan 17 farklı makine öğrenmesi modeli burada da kullanılmıştır.
- 65+ yaş ve hekim oranı verileri Ridge ve LinearRegression ile çok iyi sonuçlar vermiştir. 0-14 yaş ve yatak oranı ise iyi sonuçlar verse de r^2 değeri düşük olduğu için kullanılamaktadır.

```
========== GENEL ==========
                Model  Accuracy    MAE   RMSE      R2  ErrorRate  Precision  Recall    F1
                Ridge    96.655  2.350  2.823  -1.463      3.345      0.467   0.525 0.475
           ElasticNet    95.277  2.496  2.960  -3.481      4.723      0.267   0.350 0.292
             Stacking    95.216  5.659  6.070  -5.775      4.784      0.325   0.500 0.393
              XGBoost    94.195  3.434  3.697  -5.089      5.805      0.225   0.350 0.273
    GradientBoosting    93.815  3.468  3.726  -5.871      6.185      0.217   0.325 0.258
          ExtraTrees    93.736  3.651  4.046  -6.089      6.264      0.192   0.300 0.233
              Voting    93.669  3.389  3.699  -6.304      6.331      0.242   0.325 0.267
         HoltWinters    92.929  6.667 10.511   0.027      7.071      0.792   0.784 0.774
               ARIMA    92.831  5.844  9.563   0.016      7.169      0.773   0.667 0.696
        RandomForest    92.696  4.105  4.358  -8.747      7.304      0.192   0.300 0.233
             Bagging    92.645  4.286  4.551  -8.877      7.355      0.192   0.300 0.233
             Prophet    92.517  7.593 11.381   0.180      7.483      0.857   0.792 0.807
                 KNN    92.044  5.132  5.362 -10.655      7.956      0.192   0.300 0.233
            CatBoost    92.003  4.696  5.017 -11.536      7.997      0.192   0.300 0.233
                 SVR    87.925  7.713  8.070 -29.489     12.075      0.208   0.275 0.227
HistGradientBoosting    84.003  9.512  9.894 -47.585     15.997      0.158   0.250 0.193
    LinearRegression    83.116 20.282 21.166 -79.341     16.884      0.358   0.425 0.377

========== HER HEDEF İÇİN EN İYİ (Fold 5) ==========
      Hedef            Model  Accuracy      MAE      RMSE        R2
yas_65_plus            Ridge 99.277072 0.071903  0.084541  0.864147
 hekim_oran LinearRegression 98.938370 0.025681  0.026873  0.953575
   yas_0_14         Stacking 98.464458 0.351741  0.351753 -0.335639
 yatak_oran       ElasticNet 97.308220 8.895612 10.608918  0.406247

[OK] Çıktılar yazıldı.
```

- 0-14 yaş ve yatak oranını güçlendirmek için önceki makine öğrenmesi yöntemlerinden üç tanesi çıkartılmış ve bunun yerine Baseline_Lag1 kullanılmıştır. Baseline_Lag1 bir makine öğrenmesi yöntemi değil, bir önceki yılın değerini tahmin eden tahmin algoritmasıdır. Sonuçlara bakıldığında, HistGradientBoosting ve ElasticNet en iyi sonuçları vermiştir.

```
========== HER HEDEF İÇİN EN İYİ MODEL ==========
```

	Hedef	Model	Accuracy	MAE	RMSE	R2	ErrorRate
0	yas_0_14	HistGradientBoosting	99.3851	0.1276	0.1909	0.9988	0.6149
1	yatak_oran	ElasticNet	98.6953	3.5403	4.2802	0.9974	1.3047

Topsis Gelecek Tahmini

- Hangi veri tipi hangi makine öğrenmesi modeli ile en yüksek sonucu verdiyse o model ile 2025-2030 tahminleri yapılmıştır.
- 65+ yaş için Ridge, hekim oranı için LinearRegression, 0-14 yaş için HistGradientBoosting, yatak oranı için ElasticNet kullanılmıştır.

Topsis Kullanımı

- DSÖ'nün yayınladığı raporlar incelenmiştir. Bu sonuca göre 0-14 yaş ve 0-65 yaş değerleri benefit olarak isimlendirilir, yani değeri arttıkça öncelik artan kriterdir. 65 yaş oranı yüksekse sağlık hizmeti ihtiyacı artar. 0-14 yaş oranı yüksekse, çocuk sağlığı, aile hekimliği ve doğum/çocuk hizmet ihtiyaçları artar.

- 1000 kişi başına düşen hekim ve 100 bin kişi başına düşen hastane oranı ise cost olarak geçmektedir; değeri arttıkça ihtiyaç azalan kriterdir. 1000 kişi başına düşen hekim fazlaysa, hekim açısından arz daha iyi demektir. 100 bin kişi başına yatak sayısı yüksekse, yatak kapasitesi daha iyi demektir. Yani bu oranların düşük çıkması ihtiyaç olduğunu söyler.
- Topsis'in çalışma mantığı ise aşağıda verilmiştir.

```
1. Her yıl için iller karşılaştırılır.
2. Kriter matrisi normalize edilir.
3. Normalize değerler ağırlıklarla çarpılır.
4. Benefit kriterlerde ideal en iyi = maksimum değer.
5. Cost kriterlerde ideal en iyi = minimum değer.
6. Her ilin ideale yakınlığı hesaplanır.
7. TOPSIS skoru yüksek olan il daha öncelikli olur.
```

- Topsis'te ağırlıkların belirlenmesi için "Hangi kriter en fazla ayırt edicidir?" sorusu sorulmuş ve bu hesabı bulmak amacıyla Shannon Entropi Formülü kullanılmıştır.

Topsis Sequential Resource Allocation with Feedback Problem

- Topsis hesabı yapılırken dikkat edilmesi gereken çok önemli bir konu bulunmaktadır. Topsis verileri eğer ki 2025-2030 yılları için direkt olarak hesaplanıp sonrasında sağlık bütçesi verisi ile birleştirilirse önemli bir nokta atlanmış olur.
- Örnek olarak, entropi formülünü direkt olarak 2025-2030 yılları için uygularsak, 5 yıl boyunca yüksek ihtiyaç Sinop ilinde çıkar. Eğer ki Sinop iline 2025 yılı için en yüksek bütçeyi ayırırsak, 2026 yılında Sinop'un ihtiyaçları azalmış olacaktır. Bu sebeple yeni bütçelerle 2025 ihtiyaç listesi güncellenmeli ve 2026 yılında Sinop yerine daha çok ihtiyacı olan bir şehre bütçe ayrılmalıdır.

Bütçe Modellemesi

Veri Seti

- Türkiye'nin 1999-2024 yılları arasındaki ülke bazlı yıllık genel sağlık harcama listesi alınmıştır.
- Dolar-TL'nin 1999-2024 yılları arasındaki aylık değişim grafiği alınmıştır.

Dolar-TL Verisi Çekme

- Dolar-TL'nin 2025-2030 yılları arasındaki verilerini almak için farklı kaynaklardan yararlanılmıştır.

- 2025-2026 arası gerçek verileri toplamak için X-Rates.com ve ExchangeRates.org sitelerinden veriler çekilmiştir.
- 2026 Ocak ile 2026 Mayıs arasındaki gerçek verileri toplamak için TradingEconomics ve ExchangeRates.org sitelerinden veri çekilmiştir.
- 2026 Haziran ile 2027 Ocak arasındaki verileri çekmek için TradersUnion.com ve TCMB Piyasa Katılımcıları Anketi kullanılmıştır.
- 2027 Ocak ile 2027 Kasım arası için LongForecast.com sitesi kullanılmıştır.
- 2028, 2029 ve 2 verilerini çekmek için LongForecast ve Interpolasyon siteleri kullanılmıştır.
- Gerçekleşen aylık veriler X-Rates ve TradingEconomics'ten alınmış; 2026 Haziran sonrası dönem için TCMB Piyasa Katılımcıları Anketi ile uyumlu olacak şekilde TradersUnion (kısa vade) ve LongForecast.com (uzun vade) piyasa konsensüs tahminleri kullanılmıştır. Kaynaklar arası eksik aylar doğrusal interpolasyonla doldurulmuştur.

Yıl	Gerçek	Tahmin	Kaynak Gücü
2025	12	0	%100 gerçek
2026	5	7	Karma
2027	0	12	LongForecast +interpolasyon
2028	0	12	LongForecast + interpolasyon
2029	0	12	LongForecast + interpolasyon
2030	0	12	LongForecast + interpolasyon
Toplam	**17 ay**	**55 ay**	**72 ay**

```
2025: 39.54  (gerçek)
2026: 46.32  (yarı gerçek + yarı tahmin)
2027: 55.93
2028: 66.08
2029: 83.17
2030: 96.18
```

Bütçe Modelleme

- Öncelikle 1999-2024 arasındaki sağlık harcama listesinden “yıl, toplam sağlık harcaması, kişi başına sağlık harcaması, genel devlet sağlık harcaması oranı, özel sektör sağlık harcaması oranı” verileri alındı.
- Türk lirasının değeri yıllara göre değişken olduğu ve TL’nin yükselmesinden dolayı yıllık büyüme oranının yüksek olduğu düşünüldüğü için dolar üzerinden gidilmeye

karar verildi. 1999-2024 yılları arasındaki dolar kuru alınarak yıllık bütçe miktarı dolar türüne çevrildi.

- Modelleme sırasında zaman serisi yapısını korumak için çeşitli öznitelikler türetildi (önceki yıl bütçesi, 2 yıl önceki bütçe, hareketli ortalama, yıllık değişim oranları, trend/yıl bilgisi).
- Modeli oluşturmak için on bir farklı makine öğrenmesi yöntemi denendi.

```
ARIMA
Holt
HoltDamped
CAGR5
CAGR10
Ridge
ElasticNet
Huber
RandomForest
ExtraTrees
GradientBoosting
```

- Model başarısını ölçmek için geçmiş dönem içinde test mantığı kuruldu. Özellikle son yıllara yönelik tahmin performansı kontrol edildi. Böylece modelin sadece geçmişi ezberleyip ezberlemediği değil, ileriye doğru ne kadar mantıklı tahmin verdiği de değerlendirildi.

```
========== GENEL MODEL KARŞILAŞTIRMASI — USD HEDEF, STABİL ==========
```

	Model	Accuracy	MAE	RMSE	R2	ErrorRate
4	ExtraTrees	90.210	4965.371	6157.454	-4.891	9.790
0	ARIMA	88.114	5558.844	6618.294	-8.782	11.886
1	CAGR10	88.370	5570.594	6826.324	-6.496	11.630
3	CAGR5	88.153	5633.133	6962.098	-6.648	11.847
5	GradientBoosting	88.254	5661.530	6883.718	-9.977	11.746
6	HoltAdd	86.677	6011.173	7147.547	-8.919	13.323
13	RandomForest	86.786	6126.670	7348.851	-17.982	13.214
7	HoltDampedAdd	86.119	6255.726	7406.740	-16.535	13.881
2	CAGR15	82.573	7537.832	8698.352	-50.974	17.427
11	LogPoly2Ridge	74.757	9961.716	10909.559	-100.430	25.243
12	LogRidge	73.740	10172.580	11259.960	-120.054	26.260
8	LogElasticNet	73.196	10210.917	11243.228	-134.864	26.804
9	LogHuber	73.196	10210.917	11243.228	-134.864	26.804
10	LogLinear	73.196	10210.917	11243.228	-134.864	26.804
14	TheilSen	73.192	10213.841	11247.886	-134.864	26.808

- Daha sonra en iyi performans veren modeller seçildi ve tek model yerine ağırlıklı ensemble oluşturuldu. Yani 2025-2030 tahmininde sadece bir modelin çıktısı değil, başarılı birkaç modelin dengeli ortalaması kullanıldı.

========== ENSEMBLE İÇİN SEÇİLEN MODELLER ==========

	Model	Accuracy	MAE	RMSE	R2	ErrorRate	ensemble_weight
4	ExtraTrees	90.210	4965.371	6157.454	-4.891	9.790	0.220115
0	ARIMA	88.114	5558.844	6618.294	-8.782	11.886	0.196615
1	CAGR10	88.370	5570.594	6826.324	-6.496	11.630	0.196200
3	CAGR5	88.153	5633.133	6962.098	-6.648	11.847	0.194022
5	GradientBoosting	88.254	5661.530	6883.718	-9.977	11.746	0.193049

2025-2030 Bütçe Tahmini

- Bütçe modelinde oluşturulan ensemble model burada da kullanıldı.
- Direkt TL üzerinden gelecek tahmini yapmak yanlış olacağı için dolar bazlı tahmin yapıldı.
- Elde edilen dolar sonuçları, daha önceden oluşturulan 2025-2030 Dolar-TL veri seti ile Türk lirasına çevrildi.

Model Birleşimleri

Model Birleşimleri

- Son aşamada, daha önceden hesaplanan 2025-2030 TOPSİS öncelik sırası ile 2025-2030 Türkiye bütçesi verileri birleştirilmiştir.
- Bu noktada dikkat edilmesi gereken önemli bir durum vardır. Eğer ki TOPSİS parametreleri direkt olarak 2025-2030 yılları için tahmin edilirse, Sinop ilindeki yaşlı hasta oranı yüksek olduğu için tüm yıllarda birinci çıkmaktadır. Ancak 2025 yılında en öncelikli çıkan şehirlere 2025 yılı bütçesinden yüksek oranlar ayrılırsa, yardıma ihtiyacı olan şehirler gelen bütçelerle kendilerini toplayacak ve bu sayede ihtiyaçları azalacaktır. Bu durumda, her bütçe dağıtımı sonrası TOPSİS listesinin tekrar güncellenmesi gerekmektedir.
- Bütçe önemi için literatür taranmış; bu kapsamda TOPSİS verileri arasında “bütçe” verisi çarpanının 0.25 olmasına karar verilmiştir. Bu kapsamda, her bütçe dağıtımının ardından yeni TOPSIS verileri hesaplanacak ve yeni yıllarda bütçe verisi TOPSIS’in %25’i oranında etkili olacaktır.
- 2025-2030 şehir bazlı bütçe planlaması yapılmıştır.

Gelecek Çalışmalar

Fikirler

- Yapılan çalışmada, bütçe dağıtımları için açık kaynaklı paylaşılan güçlü veriler denenmiştir.
- Gelecek çalışmalarda, farklı bir nokta olarak 2025-2030 yıllarında mezun olacak sağlık fakültesi öğrencilerine bakılabilir. Bu sayede, bütçe planlaması sonrasında sağlık meslek gruplarından mezun olacak öğrencilerin hangi şehirlere atanması gerektiğine karar verilebilir.
- Tabii, bu çalışma için çok daha kapsamlı bir ekip çalışması ve gerekli veri izinlerinin alınması gerekmektedir.